b UNIVERSITÄT BERN



Neuromorphe Zwillinge, schmerzfreie Bewusstseinsmaschinen und andere Monster

Der faustische Pakt der Neurowissenschaft mit der Kl

Beat Bichsel

Decoding Inequality: Kritische Perspektiven auf Machine Learning und gesellschaftliche Ungleichheit

Auswertungssitzung, 23. Mai 2025

 u^{t}

Der faustische Pakt der Neurowissenschaften mit der KI

Eine sprachphilosophisch motivierte Kritik der (häretischen?) literarischen Vernunft

Dienstag, 11. März 2025 – Bett

Bern

Berner Forscher wollen einen Pakt mit der KI schliessen

Rasante Entwicklung Was, wenn künstliche Intelligenz wie ein Mensch zu denken beginnt? Zwei Wissenschaftler der Uni Bern möchten für diesen Fall einen Vertrag zwischen Menschheit und Maschinen.

Carlo Senn

Der Supercomputer HAL 9000 auf dem Raumschiff hat ein Pro-blem: Er hat einen Fehler ge-macht, darum droht film die Abschaltung - also setn «Tod». Et wehrt sich mit Gewalt gegen die Computer Gefühle: «Ich habe Angst, Dave.se

Eine künstliche intelligenz, die ein Bewusstsein entwickelt. bereits in seinem Film «2001: 1 Space Odyssey» aus dem Jahr 1968 vor. Ist die künstliche intelligenz

(KI) fast 60 Jahre nach dem Film demnächst an diesem Punkt? Das glauben zumindest zwe Forscher der Universität Bern: Walter Senn, Professor für Neu-Doktor der Philosophie und Ph

Ein Pakt, Kl zu kontrollier

Und die Berner Forscher fordern: Sollte die Menschheit dereinst von thnen geschaffenen künstlt chen Wesen ein Bewusstsein ha Das ungleiche Team hat dazu ein wissenschaftliches Paper verfasst, «Wir möchten verhindern

scancesitich seien es ja die
wonstenden die Measchinenerwusstesten kopterer hat. «Wie
Bekannt ist, dass Sprachmoschaffen. Für die Argumentation
haben sich Beiter und Senn von
Theorien über die Rechte von
haben?» Tieren inspirieren lassen. Als be- Wenn künstliche Agenten Die Beispiele zeigen: Noch

Um das Thema besser zu veran- türlich noch mehr», betont Senn ken würde, Geht es nach den Forschaulichen, haben die Forschenden ein Gedankenexpertdurch den Staat.

der Gedankenexpertdurch den Staat.

deltes Modell darauf Antworter



nen das Abbenmen den strummen den den strummen d

rizeren inspirieren iasen, alse-wenn kunstet Weisen haben auch sie dem Menschen hänlicher wer-thre Rechte, wenn auch nicht auf den jelschen Stude.

Die Meige, den Menschen recht-auch Mitgefühl für Menschen,
Etwas, was einem bewussten lich über die Maschine zu stel- würde für die KI wohl damit be- Programm aber näher kommen

lich über die Maschine zu austelen, habe Insbesondere den
fenn, den eine Steinen der
fraud, weniger privilegierte winnen, sich einer existembelderformen, weniger privilegierte winnen an ehessen
von gielchgestellten Maschinen
beneufen. Sein bei den Schmerzsen der
von gielchgestellten Maschinen
beneufen, sagt eine
zumächts jede neur Prechnologe
den gesellschaftlich (tingleichheit, sagen die Forscher. Deshalb
son die strongen der
son geneur beneure
das weiter
son der
s

menleben zu ermöglichen, bräuchte es neben dem Pakt na-denn eine Maschine bewusst den-

zusätzlich in der «Schaltzentra- schauen können.

Interessant ist dabet vor allem Realität werden.

die dritte Art von Neuronen.

Denn deren Aufgabe ist es, zu unterscheiden, was wir als «real»
entfernter Verwandter des Autors.

«Im Traum sind überzeugt, dass wir in der tät leben.» Neuronen, die u terne Vorstellungen generieren sind gleichzeitig aktiv mit der Neuronen, die uns mitteilen, die Signale kämen von aussen. «Nu so können wir mit dem Träumer ein realitätsnahes Verhalten st-mulieren und erlernen.» Senn bringt ein Beispiel: Auf

etner Safart blicken Ste plötzlich einer Safan blicken Sie plotzitch gebannt in die Augen eines Lö-wen. e.ks ist dann günstiger, Sie träumen nachts, wie Sie sich vor dem Löwen knapp ins Auto retten können, als dass Ste aus dem Auto steigen und den Löwen

Senn und Benttez sind der Meinung, dass bei der Ki Ähnliches vorgehen könnte. Sie ver-gleichen das Träumen des Menschen mit dem Trainingsmodus von KL Das Hirn verarbeitet das Erlebte, lernt Neues, schafft Ord-

xen Abläufen unterscheidet sich die KI unter anderem dadurch liefern. Denn für Senn als Wissen-schaftler sind die Vorgänge im Hirn keine Magie, sondern blochemische Prozesse. Mit dem Mo- weise ein Objekt als Tasse.

del will sen nadas Bewustseinet-was eentmystiftzieren und zu-gränglicher machen, wie er sette und zu-gränglicher machen, wie er sette voor sette sie gibt also keinen vorge-schriebenen Ablauf des Pro-gramms: Die KI findet durch die neuronalen Netzwerke quast iheine Instanz gibt, die die ver- ren eigenen Weg und trifft auch eine installt giot, die die Ver-schiedenen Informationsströme eigene Einschiedungen. Auch ein steuert und abwägt.» Der Dirf-gent Im Hirn, Damit wir in der sich anzupassen, tagsüber und Welt handeln und bestehen kön-im Traum, um die richtigen innen, muss der Dirigent einen der formationsströme zu generiere vielen Informationsströme aus- und auszuwählen

wällen, verstärken und umset-zen. Damit wird uns diese Infor-mation abewussts.

Aberwie testet man Bewusstsein? Die Forscher haben sich am zwischen Realität, Vorstellung Turing-Test orientiert, der durch und Traum, wäre das ein weite-Turing-Test orientiert, der durch Fragen und Antworten heraus-findet, ob eine Maschine «Intel-ligent» ist. Um den Test auf das Bewusstsein auszuweiten, soll Ware und Hardware hinein-

les die Funktion eines Dirigen-ten identifiziert werden.

Der Dirigent, selber nur ein

Vielleicht werden wir bald vor künstlichen Agenten umgeber sein, die von sich behaupten, Be neuronales Netzwerk, steuert ge-mäss dem Modell im Gehirn drei geschlagene Hardware dazu in mass dem Model im Jenim der verschiedene Gruppen von Neber verschiedene Neber vers

Interpreteren;
— Neurone, die von innen vor-stellungen von Sinneseindrü-cken generteren; und
— Neurone, die zwischen extern
— Neurone, die zwischen extern und intern generierten Signalen Senn. Damit die Dystopien in de

Rasante Entwicklung Was, wenn künstliche Intelligenz wie ein Mensch zu denken beginnt? Zwei Wissenschaftler der Uni Bern möchten für diesen Fall einen Vertrag zwischen Menschheit und Maschinen.

Uni Bern – Medienmitteilung 17. Oktober 2024



UNIVERSITÄT BERN

Media Relations

Medienmitteilung, 17. Oktober 2024

KI mit Bewusstsein – aber ohne Schmerzen?

Forschende der Universität Bern haben ein neues Modell für die Entstehung des Bewusstseins entwickelt. Das Modell spricht dafür, dass eines Tages auch künstliche Akteure, also Systeme, welche menschliches Denken imitieren, ein Bewusstsein erlangen könnten. Um den Umgang mit solchen Systemen zu regeln, schlagen die Forschenden ein Abkommen zwischen Mensch und Maschine vor: den «Human-Al Deal».

u^b Uni Bern – Medienmitteilung 17. Oktober 2024

Die Arbeit der Forschenden entstand unter anderem im Rahmen des «Human Brain Project», einem europäischen Forschungsprojekt zur digitalen Modellierung des menschlichen Gehirns, an dem neben der Universität Bern über 100 weitere Institutionen beteiligten. Insgesamt liefert sie neue Ideen für die hochaktuellen Felder der Kognitiven Neurowissenschaft und der Computational Neuroscience. «Die Forschung zu Bewusstsein wird allgemein als etwas (unwissenschaftlich) behandelt, da es schwierig ist, Bewusstsein zu messen», sagt Senn, «durch die Einführung funktionaler Korrelate und des Conductor Model of Consciousness hoffen wir, die Debatte in eine konkretere Richtung zu führen».

Blogpost

- Leitfrage: Wie (un)vernünftig und (un)kritisch ist die neurowissenschaftliche Forschung?
- Motivation/Vorgehen: In der geisteswissenschaftlichen Perspektive sich lustvoll und mit Neugier (in der Haltung eines unwissenden Sokrates) mit Fragen der KI und des künstlichen Bewusstseins auseinandersetzen und.
- Ziel: Erkunden, inwiefern der Gedankengang von Benitez et al. (2024) in dieser 3. Perspektive kritikfähig ist.
- Methode: Close Reading, angereichert mit spachphilosophischer und literarischer Reflexion.
- Reflexion: Rhetorik oder Episteme? Doxa oder Häresie? Welche Sprachspiele führen 5. zu welchen Erkenntnissen? Aisthetische vs. neurowissenschaftliche Vernunft?
- Weiterführung: Welche Argumente stellt die kritischen Al-Forschung in Bezug auf Künstliche Intelligenz und 6. Maschinenbewusstsein in den Vordergrund?

$u^{\scriptscriptstyle b}$ These

Das Forschungsprojekt von Benitez et al. (2024) folgt

unbewusst –

der Dramaturgie eines **klassischen Dramas**, das im Kleid eines **Schauspiels** auftritt.

Der Pakt mit der KI – Schauspiel oder Tragödie?

Akt III (Peripetie): Der verwegene Plan

Der Chip repräsentiert in diesem Gedankenexperiment eben einen Agenten, der die Hirnfunktionen und wohl auch das Bewusstsein kopiert hat. «Wie könnte man diesem Baby dann absprechen, ein Bewusstsein zu haben?»

Akt I (Exposition, ZOPEF): Die gute Absicht «Wir möchten verhindern, dass eine Konkurrenz zwischen den Rechten von Menschen und jenen von künstlichen Akteuren entsteht», sagt Benitez. Sie nennen das Abkommen den «Human-Al-Deal».

Akt II (Steigerung): Lautere Motive Erfahrungsgemäss verstärke zunächst jede neue Technologie die gesellschaftliche Ungleichheit, sagen die Forscher. [«erregendes Moment»] Deshalb versuchen sie, neben ihrer Forschung über das Hirn und Bewusstsein auch Ideen einzubringen, wie wir als Gesellschaft mit der Möglichkeit von künstlichem Bewusstsein umgehen können.

Berner Forscher wollen einen Pakkt IV (Retardierung): Hinderliche Skepsis
Eine weitere Studie der Universität Bamberg (Deutschland) ist skeptischer: Aus mit der KI schliess erechnischen Gründen sei Bewusstsein bei KI-Systemen gegenwärtig nicht möglich.



[Zerschlagung des Knotens]

Etwas, was einem bewussten Programm aber näher kommen könnte, sind «generative adversariale Netzwerke».

Der Dirigent kann Neurone verstärken, die uns die Empfindung von «real» vermitteln oder von lediglich «vorgestellt ». Mit der dritten Klasse von Neuronen kann er uns aber auch vorgaukeln, dass wir unsere Vorstellung als real empfinden. Genau das geschieht, wenn wir träumen.

Akt V (Katastrophe): friedliche Koexistenz vs. Dystopie?

Vielleicht werden wir bald von künstlichen Agenten umgeben sein, die von sich behaupten, Bewusstsein zu haben, und die vorgeschlagene Hardware dazu in der Schaltzentrale aufweisen.

[Schauspiel, naive Idylle] Dann sei es besser für beide Seiten, jeweils von einem Bewusstsein des Gegenübers auszugehen. «Wenn wir akzeptieren, dass solche KI-Agenten ein Bewusstsein haben, ist eine friedliche Koexistenz eher möglich», sagt Senn. [Tragödie, Katharsis] Damit die Dystopien in den Science-Fiction-Filmen nicht zur Realität werden.

$u^{^{\scriptscriptstyle b}}$

Das verwegene Spiel um Macht, Big Tech und Menschenwürde

- Lässt sich Künstliche Intelligenz (KI) und Maschinenbewusstsein(MB) zum Wohle der Menschen bzw. der Menschheit einsetzen?
- 2. Wie ist einem allenfalls abgründigen Spiel neurowissenschaftlicher (Un-)Vernunft beizukommen?
- 3. Welche Bedeutung kommt in diesem Zusammenhang der Kunst, Literatur und Philosophie zu?
- 4. Wie finden Körper und Geist begrifflich zueinander?

u^{\flat} What Is It Like to Be a Machine?

- Inwiefern beeinflusst die Art und Weise, wie wir über die KI bzw. MB nachdenken und sprechen (unser sprachlicher Zugriff auf die Welt)
 - i) unser Wissen von KI bzw. MB
 - ii) unser Verhalten und unsere Rechtsauffassung gegenüber Kl bzw. MB
 - iii) unser Selbstverständnis
 - iv) unser Menschenbild / unser soziales Verständnis
 - v) unser Weltbild
- 2. Wie wichtig sollten wir unser Bewusstsein nehmen?

u^b Die Spur der neuronalen Kernschmelze

- 1. Wie gross ist dein Vertrauen in die Rechtschaffenheit der (neuro)wissenschaftlichen Forschung?
- 2. Welche guten Gründe sprechen für bzw. gegen dieses Vertrauen?
- 3. Was müsste sich ändern, damit dieses Vertrauen wächst?
- 4. Was spricht für bzw. gegen die Verbindung neuromorpher Chip-Architektur mit biologischen Zellen?
- 5. Was sind die ethischen Kriterien für eine menschenzentrierte neurowissenschaftliche Forschung?

Der neuromorphe en Twin

- 1. Was löst das von Benitez et al. (2024) skizzierte konkrete Bild (vgl. Zitat) eines neuromorphen en Twins bei dir aus?
- 2. Was löst die Vision eines neuromorphen en Twins bei dir aus?

3. Wie beantwortest du die Frage von Ralf Otte: Wie weit wollen wir

gehen?



u^b Das 'Bewusstsein' des neuromorphen 'Dirigenten'

- 1. Wie beurteilst du die aufgrund neurotechnologischer Verfahren gegebene Möglichkeit, die elektrischen Impulse eines biologischen Gehirns in einem nicht-biologischen Substrat/Medium abzubilden?
- 2. Wer bzw. was organisiert das Zusammenspiel der unterschiedlichen 'Instanzen' in deinem Organismus?
- 3. Bist du ein:e (heimliche:r) Animist:in? Inwiefern? Was hält dich davon ab?

u^b Die sprachliche Gestalt der Dinge

- Inwiefern führt das neurowissenschaftliche Sprachspiel zu Irritationen und Verwirrung?
- 2. Ist Wittgensteins Methode der 'übersichtliche Darstellung' hilfreich? Inwiefern?
- 3. Was ist zu tun, damit man sich in die Richtung eines nicht dogmatischen Denkens und Sprechens bewegen kann?

Einsicht in den «Chinese Room» – eine Übersicht

- 1. Bietet der erweiteret Turing Test (eTT) Einsicht in den «Chinese Room»? Was spricht dafür, was dagegen?
- 2. Inwiefern überzeugt dich das Argument des *mereologischen Fehlschlusses*? Inwiefern nicht?
- 3. Was für Strategien gibt es, um dem *mereologischen Fehlschluss* zu entgehen?

,Next Generation' – das Paradies der Transhumanisten

- 1. Was ist eigentlich genau das Verwegene am Fortschrittsglauben, dem 'Next Generation'-Denken? Was das Positive?
- 2. Wie bildest du dir in Bezug auf diese Frage eine begründete Meinung?
- 3. Was spricht dafür, dass die Menschen als Menschheit vernünftig sind, was dagegen?
- 4. Was ist zu tun, damit wir uns Frage 3 nicht stellen müssen?

Der Human-Al-Deal im Licht des Neuronenfeuers künstlicher Augen

- 1. Wie wichtig ist es, dass wir über einen Human-Al-Deal nachdenken?
- 2. Wie 'slippery' ist der 'slope' auf dem wir uns befinden? Oder ist das Argument der ,schiefen Ebene' ein Scheinargument, das notwendigerweise zu Trugschlüssen führt?
- 3. Was für ein Satz müsste deiner Meinung nach als wichtigste Bestimmung in einer Präambel zu Human-Al-Deal stehen?

Die Auf-klärung des Mephistopheles' – eine Häresie

- 1. Was für Massnahmen und Strategien schützen vor den 'Zauberlehrlingen' z. B. in den Neurowissenschaften - und was schützt die 'Zauberlehrlinge' vor sich selbst?
- 2. Inwiefern überzeugt dich der Denkansatz und die Argumentation in meinem Blogpost? Inwiefern nicht?
- 3. Was hast du für Überarbeitungsvorschläge?

Organisationseinheit

